



凸优化理论与应用

第一章 凸集



仿射集(Affine sets)

- 直线的表示:

$$y = \theta x_1 + (1 - \theta)x_2, \theta \in \mathcal{R}.$$

- 线段的表示:

$$y = \theta x_1 + (1 - \theta)x_2, \theta \in [0, 1].$$

- 仿射集的定义: 过集合**C**内任意两点的直线均在集合**C**内, 则称集合**C**为仿射集。
- 仿射集的例子: 直线、平面、超平面

$$Ax = b$$



仿射集

- 仿射包：包含集合 C 的最小的仿射集。

$$\text{aff } C = \left\{ \sum \theta_i x_i \mid x_i \in C, \sum \theta_i = 1 \right\}$$

- 仿射维数：仿射包的维数。

- 相对内点（relative interior）：

$$\text{relint } C = \{x \mid B(x, r) \cap \text{aff} C \subseteq C, r > 0\}$$



凸集(Convex Sets)

- 凸集的定义：集合 C 内任意两点间的线段均在集合 C 内，则称集合 C 为凸集。

$$\forall x_1, x_2 \in C, \theta \in [0, 1], \text{ 则 } \theta x_1 + (1 - \theta)x_2 \in C$$

$$\forall x_1, \dots, x_k \in C, \theta_i \in [0, 1] \text{ 且 } \sum_{i=1}^k \theta_i = 1,$$

$$\text{则 } \sum_{i=1}^k \theta_i x_i \in C$$



凸集

- 凸包的定义：包含集合**C**的最小的凸集。

$$\text{conv } C = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \geq 0, \sum_{i=1}^k \theta_i = 1 \right\}$$



锥 (Cones)

- 锥的定义:

$\forall x \in C, \theta \geq 0$, 则有 $\theta x \in C$.

- 凸锥的定义: 集合 **C** 既是凸集又是锥。

$\forall x_1, x_2 \in C, \theta_1, \theta_2 \geq 0$, 则有 $\theta_1 x_1 + \theta_2 x_2 \in C$.

- 锥包的定义: 集合 **C** 内点的所有锥组合。

$$\left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \geq 0 \right\}$$



超平面和半空间

- 超平面(hyperplane) : $\{x \mid a^T x = b\}$
- 半空间(Halfspace): $\{x \mid a^T x \leq b\}$ $\{x \mid a^T x \geq b\}$



欧氏球和椭球

- 欧氏球(euclidean ball):

$$\begin{aligned} B(x_c, r) &= \{x \mid \|x - x_c\|_2 \leq r\} \\ &= \{x \mid (x - x_c)^T (x - x_c) \leq r^2\} \end{aligned}$$

- 椭球(ellipsoid):

$$E = \{x \mid (x - x_c)^T P^{-1} (x - x_c) \leq r^2\}, P \text{ 为对称正定矩阵}$$



范数球和范数锥

- 范数(**norm**): $\|x\| \geq 0, \|x\| = 0$ 当且仅当 $x = 0$;

$$\|tx\| = |t| \|x\|, t \in \mathcal{R};$$

$$\|x + y\| \leq \|x\| + \|y\|$$

- 范数球(**norm ball**):

$$B(x_c, r) = \{x \mid \|x - x_c\| \leq r\}$$

- 范数锥(**norm cone**):

$$\{(x, t) \mid \|x\| \leq t\}$$



多面体(Polyhedra)

- 多面体: $P = \{x \mid a_j^T x \leq b_j, c_i^T x = d_i\}$

- 单纯形(simplex):

$$\left\{ \sum_{i=0}^k \theta_i v_i \mid \theta_i \geq 0, \sum_{i=0}^k \theta_i = 1, v_1 - v_0, \dots, v_k - v_0 \text{线性无关} \right\}$$



半正定锥(Positive semidefinite cone)

- **n阶对称矩阵集:**


$$S^n = \{X \in \mathcal{R}^{n \times n} \mid X = X^T\}$$

- **n阶半正定矩阵集:**

$$S_+^n = \{X \in S^n \mid X \succcurlyeq 0\}$$

- **n阶正定矩阵集:**

$$S_{++}^n = \{X \in S_+^n \mid X \succ 0\}$$



**n阶半正定矩阵集为
凸锥!**



保持凸性的运算

- 集合交运算
- 仿射变换
- 透视函数(perspective function)

$$P(z, t) = z / t, z \in \mathcal{R}^n, t \in \mathcal{R}_{++}$$

- 线性分式函数(linear-fractional function)

$$f(x) = (Ax + b) / (c^T x + d)$$

$$A \in \mathcal{R}^{m \times n}, b \in \mathcal{R}^m, c \in \mathcal{R}^n, d \in \mathcal{R}, c^T x + d > 0$$



真锥(proper cone)

- 真锥的定义：锥 $K \subset R^n$ 满足如下条件

1. K 为凸集；

2. K 为闭集；

3. K 非中空；

4. K 有端点。



K 具有内点



K 内不含直线

广义不等式

- 真锥 K 下的偏序关系:

$$x \preceq_K y \Leftrightarrow y - x \in K$$

广义不等式

$$x \prec_K y \Leftrightarrow y - x \in \text{int } K$$

严格广义不等式

- 例:
 - 逐项不等式
 - 矩阵不等式



广义不等式的性质

1. $x \prec_K x$;

2. $x \prec_K y, y \prec_K x \Rightarrow x = y$;

3. $x \prec_K y, y \prec_K z \Rightarrow x \prec_K z$;

4. $x \prec_K y, u \prec_K v \Rightarrow x + u \prec_K y + v$;

5. $x \prec_K y, \alpha > 0 \Rightarrow \alpha x \prec_K \alpha y$;

6. $x_i \prec_K y_i, \lim x_i = x, \lim y_i = y \Rightarrow x \prec_K y$.



严格广义不等式的性质

$$1. x \prec_K y \Rightarrow x \preceq_K y;$$

$$2. x \not\prec_K x;$$

$$3. x \prec_K y, u \preceq_K v \Rightarrow x + u \prec_K y + v;$$

$$4. x \prec_K y, \alpha > 0 \Rightarrow \alpha x \prec_K \alpha y$$

$$5. x \prec_K y, u \text{ 足够小} \Rightarrow x + u \prec_K y.$$



最值和极值

- 最小元的定义：设 $x \in S$ ，对 $\forall y \in S$ ，都有 $x \preceq_K y$ 成立，则称 x 为 S 的最小元。
- 极小元的定义：设 $x \in S$ ，对于 $y \in S$ ，若 $y \preceq_K x$ ，则 $y = x$ 成立，则称 x 为 S 的极小元。



分割超平面(separating hyperplane)

- 定理：设 C 和 D 为两不相交凸集，则存在超平面将 C 和 D 分离。即：

$$\forall x \in C, a^T x \leq b \text{ 且 } \forall x \in D, a^T x \geq b.$$



支撑超平面(supporting hyperplane)

- 定义：设集合 C ， x_0 为 C 边界上的点。若存在 $a \neq 0$ ，满足对任意 $x \in C$ ，都有 $a^T x \leq a^T x_0$ 成立，则称超平面 $\{x \mid a^T x = a^T x_0\}$ 为集合 C 在点 x_0 处的支撑超平面。
- 定理：凸集边界上任意一点均存在支撑超平面。
- 定理：若一个闭的非中空集合，在边界上的任意一点存在支撑超平面，则该集合为凸集。

对偶锥(dual cone)

- 对偶锥的定义：设 K 为锥，则集合

$$K^* = \{y \mid x^T y \geq 0, \forall x \in K\}$$

称为对偶锥。

- 对偶锥的性质：

1. K^* 是闭凸集；

2. 若 K 非中空，则 K^* 有端点；

3. 若 K 的闭包有端点，则 K^* 非中空；

4. K^{**} 是 K 的闭凸包；

真锥的对偶锥仍
然是真锥！



对偶广义不等式

■ 广义不等式与对偶等价性质

$$x \preceq_K y \Leftrightarrow \lambda^T x \leq \lambda^T y, \text{ for all } \lambda \succeq_{K^*} 0;$$

$$x \prec_K y \Leftrightarrow \lambda^T x \leq \lambda^T y, \text{ for all } \lambda \succeq_{K^*} 0, \lambda \neq 0.$$

■ 最小元的对偶特性:

x 为集合 S 中关于 K 偏序的最小元

\Leftrightarrow 对所有 $\lambda \succeq_{K^*} 0$, x 为使 $\lambda^T z, z \in S$ 最小的值.



对偶广义不等式

■ 极小元的对偶特性

$\lambda \succ_{K^*} 0$, x 为使 $\lambda^T z, z \in S$ 最小的值 $\Rightarrow x$ 为极小元.



反过来不一定成立!



作业(1)

- P60 2.8
- P60 2.10
- P60 2.14



作业(2)

- P62 2.16
- P62 2.18
- P64 2.30
- P64 2.31
- P64 2.32



凸优化理论与应用

第二章 凸函数

凸函数的定义

- 凸函数的定义：函数 $f: \mathcal{R}^n \rightarrow \mathcal{R}$ ，满足

1. 定义域 $\text{dom } f$ 为凸集；

2. $\forall x, y \in \text{dom } f, 0 \leq \theta \leq 1$ ，有

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y).$$

- 凸函数的扩展定义：若 f 为凸函数，
展函数 $\tilde{f}: \mathcal{R}^n \rightarrow \mathcal{R} \cup \{\infty\}$ 为

$$\tilde{f}(x) = \begin{cases} f(x) & x \in \text{dom } f \\ \infty & x \notin \text{dom } f \end{cases}$$

凸函数的
扩展函数
也是凸函
数！



凸函数的一阶微分条件

- 若函数 f 的定义域 $\text{dom}f$ 为开集，且函数 f 一阶可微，则函数 f 为凸函数当且仅当 $\text{dom}f$ 为凸集，且对 $\forall x, y \in \text{dom}f$

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$



凸函数的二阶微分条件

- 若函数 f 的定义域 $\text{dom}f$ 为开集，且函数 f 二阶可微，则函数 f 为凸函数当且仅当 $\text{dom}f$ 为凸集，且对 $\forall x \in \text{dom}f$ ，其**Hessian**矩阵

$$\nabla^2 f(x) \succeq 0.$$



凸函数的例

- 指数函数 e^{ax}
- 幂函数 $x^a, x \in \mathcal{R}_{++}, a \geq 1$ or $a \leq 0$.
- 负对数函数 $-\log x$
- 负熵函数 $x \log x$
- 范数函数 $\|x\|_p$



凸函数的例

$$f(x) = \max(x_1, \dots, x_n)$$

$$f(x) = x^2 / y$$

$$f(x) = \log(e^{x_1} + \dots + e^{x_n})$$

$$f(x) = (\prod_{i=1}^n x_i)^{1/n}, \text{dom} f = \mathcal{R}_{++}^n$$

$$f(X) = \log(\det X), \text{dom} f = S_{++}^n$$



下水平集(sublevel set)

- 定义：集合

$$C_{\alpha} = \{x \in \text{dom}f \mid f(x) \leq \alpha\}$$

称为 f 的 α 下水平集。

- 定理：凸函数的任一下水平集均为凸集。
- 任一下水平集均为凸集的函数**不一定**为凸函数。



函数上半图(epigraph)

- 定义：集合

$$\text{epi}f = \{(x, t) \mid x \in \text{dom}f, f(x) \leq t\}$$

称为函数 f 的上半图。

- 定理：函数 f 为凸函数当且仅当 f 的上半图为凸集。



Jensen不等式

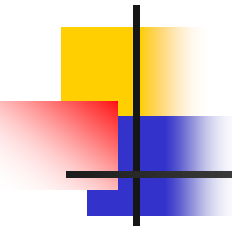
- f 为凸函数，则有：

$$f(\theta_1 x_1 + \dots + \theta_n x_n) \leq \theta_1 f(x_1) + \dots + \theta_n f(x_n)$$

其中 $0 \leq \theta_i \leq 1, \theta_1 + \dots + \theta_n = 1$.

- Jensen不等式的另外形式：

$$f\left(\int_S p(x) x dx\right) \leq \int_S p(x) f(x) dx.$$



保持函数凸性的算子

- 凸函数的非负加权和

$$f(x) = \omega_1 f_1(x) + \dots + \omega_n f_n(x)$$

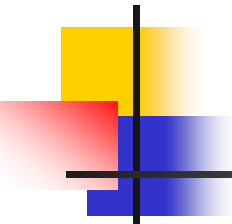
- 凸函数与仿射变换的复合

$$g(x) = f(Ax + b)$$

- 凸函数的逐点最大值

$$f(x) = \max(f_1(x), \dots, f_n(x))$$

$$f(x) = \sup_{y \in \mathcal{A}} g(x, y)$$



保持函数凸性的算子

- 复合运算

$$g: \mathcal{R}^n \rightarrow \mathcal{R}, h: \mathcal{R} \rightarrow \mathcal{R}$$
$$f(x) = h(g(x))$$

- 最小值算子

$$g(x) = \inf_{y \in C} f(x, y)$$

- 凸函数的透视算子

$$g(x, t) = tf(x/t)$$




共轭函数(conjugate function)

- 定义：设函数 $f: \mathcal{R}^n \rightarrow \mathcal{R}$ ，其共轭函数 $f^*: \mathcal{R}^n \rightarrow \mathcal{R}$ ，定义为

$$f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x)).$$

- 共轭函数的例



共轭函数
具有凸性！



共轭函数的性质

- Fenchel's inequality

$$f(x) + f^*(y) \geq y^T x.$$

- 性质：若 $f(x)$ 为凸函数，且 $f(x)$ 的上半图是闭集，则有

$$f^{**} = f.$$

- 性质：设 $f(x)$ 为凸函数，且可微，对于 $z \in R^n$ ，若

$$y = \nabla f(z)$$

则

$$f^*(y) = z^T \nabla f(z) - f(z)$$



准凸函数(quasiconvex function)

- 定义：设函数 $f : \mathcal{R}^n \rightarrow \mathcal{R}$ ，若函数的定义域和任意下水平集

$$S_{\alpha} = \{x \mid f(x) \leq \alpha, x \in \text{dom}f\}$$

则称函数 $f(x)$ 为准凸函数。

- 准凸函数的例



准凸函数的判定定理

- 定理：函数 $f(x)$ 为准凸函数，当且仅当 $\text{dom}f$ 为凸集，且对 $\forall x, y \in \text{dom}f, 0 \leq \theta \leq 1$ ，有

$$f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\}$$

- 定理：若函数 $f(x)$ 一阶可微，则 $f(x)$ 为准凸函数，当且仅当 $\text{dom}f$ 为凸集，且对 $\forall x, y \in \text{dom}f$ ，有

$$f(y) \leq f(x) \Rightarrow \nabla^T f(x)(y - x) \leq 0$$

- 定理：若函数 $f(x)$ 二阶可微，且满足对

$\forall x \in \text{dom}f, y \in \mathcal{R}^n, y \neq 0$ ，有

$$y^T \nabla f(x) = 0 \Rightarrow y^T \nabla^2 f(x) y > 0$$

则函数 $f(x)$ 为准凸函数。



保持准凸性的算子

- 非负权值函数的最大值函数
- 复合函数
- 最小值函数



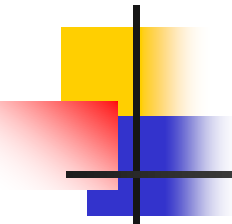
准凸函数的凸函数族表示

- 若 $f(x)$ 为准凸函数，根据 $f(x)$ 的任意 t 下水平集，我们可以构造一个凸函数族 $\phi_t(x)$ ，使得

$$f(x) \leq t \Leftrightarrow \phi_t(x) \leq 0$$

- 性质：若 $\phi_t(x)$ 为准凸函数 $f(x)$ 的凸函数族表示，对每一个 $x \in \text{dom}f$ ，若 $s \geq t$ ，则有

$$\phi_s(x) \leq \phi_t(x).$$



对数凸函数

- 定义：函数 $f(x)$ 称为对数凸函数，若函数 $f(x)$ 满足：
 1. $\text{dom}f$ 为凸集
 2. $f(x) > 0$
 3. $\log f(x)$ 为凸函数。
- 定理：函数 $f(x)$ 的定义域为凸集，且 $f(x) > 0$ ，则 $f(x)$ 为对数凸函数，当且仅当对 $\forall x, y \in \text{dom}f, 0 \leq \theta \leq 1$ 有
$$f(\theta x + (1 - \theta)y) \leq f(x)^\theta f(y)^{1-\theta}$$
- 对数凸函数的例



对数凸函数和凹函数的性质

- 定理：函数 $f(x)$ 二阶可微，则 $f(x)$ 为对数凸函数当且仅当

$$f(x)\nabla^2 f(x) \succcurlyeq \nabla f(x)\nabla f(x)^T$$

- 性质：对数凸性与凹性对函数乘积和正数数乘运算均保持封闭。
- 性质：对数凸性对函数加运算保持封闭。但对数凹性对函数加运算不封闭。
- 推论：函数 $f(x, y)$ 对每一个 $y \in C$ 在 x 上对数凸，则函数 $g(x) = \int_C f(x, y)dy$ 也是对数凸函数。



对数凸函数和凹函数的性质

- 定理：函数 $f(x, y): \mathcal{R}^n \times \mathcal{R}^m \rightarrow \mathcal{R}$ 为对数凹函数，则函数 $g(x) = \int f(x, y) dy$ 是对数凹函数。



广义不等式下的凸性

- 广义单调性的定义：设 $K \subseteq \mathcal{R}^n$ 为真锥，函数 $f: \mathcal{R}^n \rightarrow \mathcal{R}$ 称为 K -单调增，若函数 $f(x)$ 满足：

$$x \preceq_K y \Rightarrow f(x) \leq f(y)$$

- 广义凸函数的定义：设 $K \subseteq \mathcal{R}^m$ 为真锥，函数 $f: \mathcal{R}^n \rightarrow \mathcal{R}^m$ 称为 K -凸，若函数 $f(x)$ 满足对 $\forall x, y \in \text{dom}f, 0 \leq \theta \leq 1$ 均有 $f(\theta x + (1-\theta)y) \preceq_K \theta f(x) + (1-\theta)f(y)$.
- 定理(对偶等价)：函数 $f(x)$ 为 K -凸函数，当且仅当对所有 $w \succ_{K^*} 0$ ， $w^T f(x)$ 为凸函数。



练习

- P116 3.16
- P120 3.53
- P120 3.41
- P120 3.49 (1) (2)



凸优化理论与应用

第三章 凸优化



优化问题的基本形式

- 优化问题的基本描述:

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_j(x) = 0, \quad j = 1, \dots, p$$

$$\text{优化变量} \quad x \in \mathcal{R}^n$$

$$\text{不等式约束} \quad f_i(x) \leq 0$$

$$\text{等式约束} \quad h_j(x) = 0$$

$$\text{无约束优化} \quad m = p = 0$$



优化问题的基本形式

优化问题的域

$$D = \bigcap_{i=0}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$$

可行点(解) (**feasible**) $x \in D$ 满足约束条件

可行域(可解集)

所有可行点的集合

最优化值

$$p^* = \inf \{ f_0(x) \mid f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p \}$$

最优化解

$$p^* = f_0(x^*)$$



局部最优问题

■ 局部最优问题

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_j(x) = 0, \quad j = 1, \dots, p$$

$$\|x - z\|_2 \leq R, \quad R > 0$$



优化问题的等价形式(1)

- 定理：若 $\alpha_i > 0, i = 0, \dots, m, \beta_i \neq 0, i = 1, \dots, p$
则原优化问题与以下优化问题等价

$$\text{minimize } \tilde{f}_0(x) = \alpha_0 f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } \tilde{f}_i(x) = \alpha_i f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$\tilde{h}_i(x) = h_i(x) = 0, \quad i = 1, \dots, p$$



优化问题的等价形式(2)

- 定理：设 $\phi: \mathcal{R}^n \rightarrow \mathcal{R}^n$ 为一一对应，且 $D \subseteq \phi(\text{dom}\phi)$ 则原优化问题与以下优化问题等价

$$\text{minimize } \tilde{f}_0(z) = f_0(\phi(z)), \quad z \in \mathcal{R}^n$$

$$\text{subject to } \tilde{f}_i(z) = f_i(\phi(z)) \leq 0, \quad i = 1, \dots, m$$

$$\tilde{h}_i(z) = h_i(\phi(z)) = 0, \quad i = 1, \dots, p$$

优化问题的等价形式(3)

- 定理：设 $\psi_0 : \mathcal{R} \rightarrow \mathcal{R}$ 为严格单调增函数； ψ_1, \dots, ψ_m 满足 $\psi_i(u) \leq 0$ 当且仅当 $u \leq 0$ ； $\omega_1, \dots, \omega_p$ 满足 $\omega_i(u) = 0$ 当且仅当 $u = 0$ 。则原优化问题与以下优化问题等价

$$\begin{aligned} & \text{minimize} \quad \tilde{f}_0(z) = \psi_0(f_0(z)), \quad z \in \mathcal{R}^n \\ & \text{subject to} \quad \tilde{f}_i(z) = \psi_i(f_i(z)) \leq 0, \quad i = 1, \dots, m \\ & \quad \quad \quad \tilde{h}_i(z) = \omega_i(h_i(z)) = 0, \quad i = 1, \dots, p \end{aligned}$$



优化问题的等价形式(4)

- 定理：原优化问题与以下优化问题等价

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) + s_i = 0, \quad i = 1, \dots, m$$

$$s_i \geq 0$$

$$h_j(x) = 0, \quad j = 1, \dots, p$$

- s 称为松弛变量



优化问题的等价形式(5)

- 定理：设 $\phi: \mathcal{R}^k \rightarrow \mathcal{R}^n$ 满足等式 $h_j(x) = 0, j = 1, \dots, p$ 成立，当且仅当 $x = \phi(z)$ 。则原优化问题与以下优化问题等价

$$\begin{aligned} & \text{minimize} && f_0(\phi(z)), \quad x \in \mathcal{R}^n \\ & \text{subject to} && f_i(\phi(z)) \leq 0, \quad i = 1, \dots, m \end{aligned}$$



可分离变量优化问题

■ 性质:
$$\inf_{x,y} f(x,y) = \inf_x \tilde{f}(x)$$

其中
$$\tilde{f}(x) = \inf_y f(x,y)$$

■ 定理: 优化问题

$$\begin{aligned} & \text{minimize} && f_0(x_1, x_2), \quad x \in \mathcal{R}^n \\ & \text{subject to} && f_i(x_1) \leq 0, \quad i = 1, \dots, m_1 \\ & && \tilde{f}_i(x_2) \leq 0, \quad i = 1, \dots, m_2 \end{aligned}$$

可以分离变量 x_1, x_2



优化问题的上半图形式

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && f_0(x) - t \leq 0, \\ & && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && h_j(x) = 0, \quad j = 1, \dots, p \end{aligned}$$



凸优化问题的基本形式

- 凸优化问题的基本描述:

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_j(x) = 0, \quad j = 1, \dots, p$$

$f_i(x)$ 为凸函数

$h_j(x)$ 为仿射函数

若 $f_0(x)$ 为准凸函数，则优化问题称为准凸优化问题。

性质：凸优化问题的可行域是凸集。



凸优化问题的例

■ 例:

$$\text{minimize } f_0(x) = x_1^2 + x_2^2$$

$$\text{subject to } f_1(x) = x_1 / (1 + x_2^2) \leq 0$$

$$h_1(x) = (x_1 + x_2)^2 = 0$$

等价于凸优化问题

$$\text{minimize } f_0(x) = x_1^2 + x_2^2$$

$$\text{subject to } \tilde{f}_1(x) = x_1 \leq 0$$

$$\tilde{h}_1(x) = x_1 + x_2 = 0$$



凸优化问题的局部最优解

- 定理：凸优化问题的局部最优解均是全局最优解。



凸优化问题最优解的微分条件

- 定理：设 X 为凸优化问题的可行域， $f_0(x)$ 可微。则 x 为最优解当且仅当 $\nabla f_0(x)^T (y - x) \geq 0, y \in X$ 成立。
- 定理：非约束凸优化问题中，若 $f_0(x)$ 可微。则 x 为最优解当且仅当 $\nabla f_0(x) = 0$ 成立。



凸优化问题的等价形式

- 定理：设凸优化问题仅有等式约束

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } Ax = b$$

则 x 为最优解当且仅当 $x \in X$ ，且存在向量 v 满足

$$\nabla f_0(x) + A^T v = 0$$



凸优化问题的等价形式

- 定理：设凸优化问题

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } x \succeq 0$$

则 x 为最优解当且仅当 $x \in X$, 且

$$\nabla f_0(x)^T x = 0$$



凸优化问题的等价形式

- 定理：设凸优化问题

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$A^T x = b$$

等价于

$$\text{minimize } f_0(Fz + x_0), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(Fz + x_0) \leq 0, \quad i = 1, \dots, m$$

其中

$$A^T x = b \Leftrightarrow x = Fz + x_0$$



凸优化问题的等价形式

- 定理：设凸优化问题

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } a_i^T x \leq b_i, \quad i = 1, \dots, m$$

等价于

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } a_i^T x + s_i = b_i, \quad i = 1, \dots, m$$

$$s_i \geq 0, \quad i = 1, \dots, m$$



准凸优化问题

- 准凸优化问题的基本描述

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_j(x) = 0, \quad j = 1, \dots, p$$

$f_0(x)$ 为准凸函数, $f_1(x), \dots, f_m(x)$ 为凸函数。

- 注：准凸优化问题的局部最优解不一定是全局最优解。



准凸优化问题的上半图形式

- 设 $\phi_t(x)$ 为准凸函数 $f_0(x)$ 的凸函数族表示, 即

$$f_0(x) \leq t \Leftrightarrow \phi_t(x) \leq 0$$

则准凸优化问题的可行解问题为

find x

subject to $\phi_t(x) \leq 0,$

$$f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$Ax = b$$

- 设 p^* 为准凸优化问题的最优解, 若上述问题可解, 则 $p^* \leq t$ 。否则 $p^* \geq t$ 。



准凸优化问题二分法求解

- 给定一个足够小的 l 和足够大的 u ，使得区间 $[l, u]$ 能包含最优解 p^* 。给定 $\varepsilon > 0$
- **LOOP:**
 - 令 $t = (l + u) / 2$
 - 求解可行解问题；
 - 若可解，则令 $u = t$ ，否则令 $l = t$
 - 若 $|u - l| < \varepsilon$ ，则结束，否则**goto LOOP**。



线性规划(linear program,LP)

■ LP问题的一般描述

$$\text{minimize} \quad c^T x + d$$

$$\text{subject to} \quad Gx \preceq h$$

$$Ax = b$$

$$G \in \mathcal{R}^{m \times n}, A \in \mathcal{R}^{p \times n}$$



LP问题的几种类型

- 标准LP问题

$$\text{minimize } c^T x$$

$$\text{subject to } Ax = b$$

$$x \succeq 0$$

- 不等式形式LP问题

$$\text{minimize } c^T x + d$$

$$\text{subject to } Ax \preceq b$$



标准LP问题的转换

$$\text{minimize} \quad c^T x^+ - c^T x^- + b$$

$$\text{subject to} \quad Gx^+ - Gx^- + s = h$$

$$Ax^+ - Ax^- = b$$

$$x^+ \succeq 0, x^- \succeq 0, s \succeq 0$$



LP问题的例

- Chebyshev center of a polyhedron
- Piecewise-linear minimization
- Linear-fractional programming



Chebyshev center of a polyhedron

- 多面体 $P = \{x \in R^n \mid Ax \preceq b\}$
- Chebyshev center: 到多面体边界距离最大的内点（最深的点）
- 问题描述
$$\begin{aligned} & \text{maximize} && r \\ & \text{subject to} && B(x_c, r) \subseteq P \\ & && B(x_c, r) = \{x_c + u \mid \|u\|_2 \leq r\} \end{aligned}$$
- LP形式
$$\begin{aligned} & \text{minimize} && 1/r \\ & \text{subject to} && a_i^T x_c + r \|a_i\|_2 \leq b_i, i = 1, \dots, m \end{aligned}$$



Piecewise-linear minimization

- 问题描述

$$\text{minimize} \quad f(x) = \max_{i=1,\dots,m} (a_i^T x + b_i)$$

- 上半图形式

$$\text{minimize} \quad t$$

$$\text{subject to} \quad \max_{i=1,\dots,m} (a_i^T x + b_i) \leq t$$

- LP形式

$$\text{minimize} \quad t$$

$$\text{subject to} \quad a_i^T x + b_i \leq t, i = 1, \dots, m$$

Linear-fractional programming

■ 问题描述

$$\text{minimize } f_0(x) = \frac{c^T x + d}{e^T x + f}, \text{dom} f_0 = \{x \mid e^T x + f > 0\}$$

$$\text{subject to } Gx \preceq h$$

$$Ax = b$$

■ LP形式

$$\text{minimize } c^T y + dz$$

$$\text{subject to } Gy - hz \preceq 0$$

$$Ay - bz = 0$$

$$e^T y + fz = 1$$

$$z \geq 0$$

$$y = \frac{x}{e^T x + f}$$

$$z = \frac{1}{e^T x + f}$$



二次规划(quadratic program, QP)

■ QP问题的基本描述

$$\text{minimize} \quad (1/2)x^T P x + q^T x + r$$

$$\text{subject to} \quad Gx \preceq h$$

$$Ax = b$$

$$P \in S_+^n, G \in R^{m \times n}, A \in R^{p \times n}$$



二次约束二次规划

- quadratically constrained quadratic program (QCQP)

$$\text{minimize} \quad (1/2)x^T P_0 x + q_0^T x + r_0$$

$$\text{subject to} \quad (1/2)x^T P_i x + q_i^T x + r_i \leq 0$$

$$Ax = b$$

$$P_i \in S_+^n, A \in R^{p \times n}$$



QP问题的例

- Least-squares and regression
- Distance between polyhedra



Least-squares and regression

- 问题描述

$$\text{minimize} \quad \|Ax - b\|_2^2$$

$$\|Ax - b\|_2^2 = x^T A^T A x - 2b^T A x + b^T b$$



Distance between polyhedra

- 问题描述

$$\text{dist}(P_1, P_2) = \inf\{\|x_1 - x_2\| \mid x_1 \in P_1, x_2 \in P_2\}$$

$$P_1 = \{x \mid A_1 x \preceq b_1\} \quad P_2 = \{x \mid A_2 x \preceq b_2\}$$

- QP形式

$$\text{minimize} \quad \|x_1 - x_2\|_2^2$$

$$\text{subject to} \quad A_1 x \preceq b_1, A_2 x \preceq b_2$$



Second-order cone program, SOCP

- SOCP问题的基本描述

$$\text{minimize } f^T x$$

$$\text{subject to } \|A_i x + b\|_2 \leq c_i^T x + d_i$$

$$Fx = g$$

- 二次锥约束条件

$$\|Ax + b\|_2 \leq c^T x + d$$



SOCP问题的例—Robust linear programming

- 问题描述

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && a_i^T x \leq b_i \end{aligned}$$

其中 c, a_i, b_i 不是完全确定的常数。

- 例： c, b_i 为确定的常数， a_i 为变量，其范围满足

$$a_i \in \varepsilon_i = \{\bar{a}_i + P_i u \mid \|u\|_2 \leq 1\}$$

SOCP形式

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \bar{a}_i^T x + \|P_i^T x\|_2 \leq b_i \end{aligned}$$



几何规划(Geometric programming)

- 几何规划的基本描述

$$\text{minimize } f_0(x)$$

$$\text{subject to } f_i(x) \leq 1, i = 1, \dots, m$$

$$h_i(x) = 1, i = 1, \dots, p$$

f_i 为多项式, h_i 为单项式, $D = R_{++}^n$

- 单项式与多项式

$$f(x) = cx_1^{a_1} \cdots x_n^{a_n}$$

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} \cdots x_n^{a_{nk}}$$



几何规划的凸形式转换

■ 令

$$y_i = \log x_i$$

■ 几何规划的凸形式

$$\text{minimize } \tilde{f}_0(y) = \log\left(\sum_{k=1}^{K_0} e^{a_{0k}^T y + b_{0k}}\right)$$

$$\text{subject to } \tilde{f}_i(y) = \log\left(\sum_{k=1}^{K_i} e^{a_{ik}^T y + b_{ik}}\right) \leq 0, i = 1, \dots, m$$

$$\tilde{h}_i(y) = g_i^T y + h_i = 0, i = 1, \dots, p$$



广义不等式约束

- 广义不等式约束的优化问题

$$\text{minimize } f_0(x)$$

$$\text{subject to } f_i(x) \preceq_{K_i} 0, i = 1, \dots, m$$

$$Ax = b$$

- SOCP的描述

$$\text{minimize } c^T x$$

$$\text{subject to } -(A_i x + b_i, c_i^T x + d_i) \preceq_{K_i} 0, i = 1, \dots, m$$

$$Fx = g$$

$$K_i = \{(y, t) \in R^{k_i+1} \mid \|y\|_2 \leq t\}$$



凸优化理论与应用

第四章 对偶问题



优化问题的拉格朗日函数

- 设优化问题:

$$\text{minimize } f_0(x), \quad x \in \mathcal{R}^n$$

$$\text{subject to } f_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_j(x) = 0, \quad j = 1, \dots, p$$

- 拉格朗日(Lagrangian)函数:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

- 对固定的 x , 拉格朗日函数 $L(x, \lambda, \nu)$ 为关于 λ 和 ν 的仿射函数。



拉格朗日对偶函数

- 拉格朗日对偶函数(lagrange dual function) :

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) = \inf_{x \in D} (f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x))$$

若拉格朗日函数没有下界, 则令

$$g(\lambda, \nu) = -\infty$$

- 拉格朗日对偶函数为凹函数。
- 对 $\forall \lambda \succeq 0$ 和 $\forall \nu$, 若原最优化问题有最优值 p^* , 则

$$g(\lambda, \nu) \leq p^*$$



对偶函数的例

- **Least-squares solution of linear equations**
- **Standard form LP**
- **Two-way partitioning problem**



Least-squares solution of linear equations

- 原问题: minimize $x^T x, x \in \mathcal{R}^n$
 subject to $Ax = b$
- 拉格朗日函数:
$$L(x, \nu) = x^T x + \nu^T (Ax - b)$$
- 拉格朗日对偶函数:
$$g(\nu) = -\frac{1}{4} \nu^T A A^T \nu - b^T \nu$$



Standard form LP

- 原问题:
$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax = b \\ & && x \succeq 0 \end{aligned}$$
- 拉格朗日函数:
$$\begin{aligned} L(x, \lambda, \nu) &= c^T x - \lambda^T x + \nu^T (Ax - b) \\ &= -\nu^T b + (c - \lambda + A^T \nu)^T x \end{aligned}$$
- 拉格朗日对偶函数:
$$g(\lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}$$



Two-way partitioning problem

- 原问题: minimize $x^T W x, W \in S^n$
 subject to $x_i^2 = 1, i = 1, \dots, n$

- 拉格朗日函数:

$$\begin{aligned} L(x, \nu) &= x^T W x + \sum_{i=1}^n \nu_i (x_i^2 - 1) \\ &= x^T (W + \text{diag}(\nu)) x - 1^T \nu \end{aligned}$$

- 拉格朗日对偶函数:

$$g(\nu) = \begin{cases} -1^T \nu & W + \text{diag}(\nu) \succeq 0 \\ -\infty & \text{otherwise} \end{cases}$$



对偶函数与共轭函数

- 共轭函数 $f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x))$
- 共轭函数与对偶函数存在密切联系
- 具有线性不等式约束和线性等式约束的优化问题:

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && Ax \preceq b \\ & && Cx = d \end{aligned}$$

对偶函数:

$$g(\lambda, \nu) = -b^T \lambda - d^T \nu - f_0^*(-A^T \lambda - C^T \nu)$$



Equality constrained norm minimization

- 问题描述:
$$\begin{aligned} &\text{minimize} \quad \|x\| \\ &\text{subject to} \quad Ax = b \end{aligned}$$

- 共轭函数:

$$f_0^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{otherwise} \end{cases}$$

- 对偶函数:

$$g(v) = -b^T v - f_0^*(-A^T v) = \begin{cases} -b^T v & \| -A^T v \|_* \leq 1 \\ -\infty & \text{otherwise} \end{cases}$$



Entropy maximization

- 原始问题: minimize $\sum_{i=1}^n x_i \log x_i$, $D = R_+^n$
subject to $Ax \preceq b$
 $1^T x = 1$
- 共轭函数:
$$f_0^*(y) = \sum_{i=1}^m e^{y_i - 1}$$
- 对偶函数:
$$\begin{aligned} g(\lambda, \nu) &= -b^T \lambda - \nu - f_0^*(-A^T \lambda - 1\nu) \\ &= -b^T \lambda - \nu - \sum_{i=1}^m e^{-a_i^T \lambda - \nu - 1} \\ &= -b^T \lambda - \nu - e^{-\nu - 1} \sum_{i=1}^m e^{-a_i^T \lambda} \end{aligned}$$



Minimum volume covering ellipsoid

■ 原始问题:

$$\begin{aligned} & \text{minimize} \quad \log \det X^{-1}, \quad D = S_{++}^n \\ & \text{subject to} \quad a_i^T X a_i \leq 1, i = 1, \dots, m \end{aligned}$$

■ 共轭函数:

$$f_0^*(Y) = \log \det(-Y)^{-1} - n$$

■ 对偶函数:

$$g(\lambda) = \begin{cases} \log \det(\sum_{i=1}^m \lambda_i a_i a_i^T) - 1^T \lambda + n & \sum_{i=1}^m \lambda_i a_i a_i^T \succ 0 \\ -\infty & \text{otherwise} \end{cases}$$



拉格朗日对偶问题

- 拉格朗日对偶问题的描述:

$$\text{maximize } g(\lambda, \nu)$$

$$\text{subject to } \lambda \succeq 0$$

- 对偶可行域 $\lambda \succeq 0$

$$g(\lambda, \nu) > -\infty$$

- 最优值 d^*

- 最优解 (λ^*, ν^*)



LP问题的对偶问题

- 标准LP问题 minimize $c^T x$
 subject to $Ax = b$
 $x \succeq 0$

- 对偶函数

$$g(\lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}$$

- 对偶问题

$$\begin{aligned} &\text{minimize} && g(\lambda, \nu) \\ &\text{subject to} && \lambda \succeq 0 \end{aligned}$$

- 等价描述

$$\begin{aligned} &\text{minimize} && g(\lambda, \nu) \\ &\text{subject to} && A^T \nu - \lambda + c = 0 \\ &&& \lambda \succeq 0 \end{aligned}$$



弱对偶性

- 定理（弱对偶性）：设原始问题的最优值为 p^* ，对偶问题的最优值为 d^* ，则 $d^* \leq p^*$ 成立。
- **optimal duality gap**
$$p^* - d^*$$
- 可以利用对偶问题找到原始问题最优解的下界。

强对偶性

- 定义（强对偶性）：设原始问题的最优值为 p^* ，对偶问题的最优值为 d^* 。若 $d^* = p^*$ 成立，则称原始问题和对偶问题之间具有**强对偶性**。
- 强对偶性并不是总是成立的。
- 凸优化问题**通常（但并不总是）**具有强对偶性。
- **Slater定理**：若凸优化问题存在严格可行解，即存在 $x \in \text{relint } D$ ，满足
$$f_i(x) < 0, i = 1, \dots, m,$$
$$Ax = b$$

则优化问题具有强对偶性。该条件称为**Slater条件**。



强对偶性

- 弱化的**Slater**条件：若不等式约束条件的前 k 个为线性不等式约束条件，则**Slater**条件可以弱化为：
存在 $x \in \text{relint } D$ ，满足

$$f_i(x) \leq 0, i = 1, \dots, k,$$

$$f_i(x) < 0, i = k + 1, \dots, m,$$

$$Ax = b$$

- 原问题:
$$\begin{aligned} & \text{minimize} && x^T x, \quad x \in \mathcal{R}^n \\ & \text{subject to} && Ax = b \end{aligned}$$

- 对偶问题:

$$\text{maximize} \quad g(v) = -\frac{1}{4}v^T A A^T v - b^T v$$

- 具有强对偶性



Lagrange dual of QCQP

- **QCQP:** minimize $(1/2)x^T P_0 x + q_0^T x + r_0$
subject to $(1/2)x^T P_i x + q_i^T x + r_i \leq 0$

- **拉格朗日函数:**

$$L(x, \lambda) = \frac{1}{2} x^T P(\lambda) x + q(\lambda)^T x + r(\lambda)$$

$$P(\lambda) = P_0 + \sum_{i=1}^m \lambda_i P_i \quad q(\lambda) = q_0 + \sum_{i=1}^m \lambda_i q_i \quad r(\lambda) = r_0 + \sum_{i=1}^m \lambda_i r_i$$

- **对偶函数:**

$$g(\lambda) = \inf_x L(x, \lambda) = -\frac{1}{2} q(\lambda)^T P(\lambda)^{-1} q(\lambda) + r(\lambda)$$



Lagrange dual of QCQP

- 对偶问题:

$$\begin{aligned} & \text{maximize} && -\frac{1}{2} q(\lambda)^T P(\lambda)^{-1} q(\lambda) + r(\lambda) \\ & \text{subject to} && \lambda \succeq 0 \end{aligned}$$

- Slater条件: 存在 x , 满足

$$(1/2)x^T P_i x + q_i^T x + r_i < 0, i = 1, \dots, m$$



Entropy maximization

- 原始问题: minimize $\sum_{i=1}^n x_i \log x_i, \quad D = R_+^n$
subject to $Ax \preceq b$
 $1^T x = 1$
- 对偶函数: $g(\lambda, \nu) = -b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^T \lambda}$
- 对偶问题: maximize $-b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^T \lambda}$
subject to $\lambda \succeq 0$



Entropy maximization

- 弱化的Slater条件：存在 $x \succ 0$ ，满足

$$Ax \preceq b$$

$$1^T x = 1$$



Minimum volume covering ellipsoid

- 原始问题:

$$\begin{aligned} & \text{minimize} && \log \det X^{-1}, \quad D = S_{++}^n \\ & \text{subject to} && a_i^T X a_i \leq 1, i = 1, \dots, m \end{aligned}$$

- 对偶函数:

$$g(\lambda) = \begin{cases} \log \det(\sum_{i=1}^m \lambda_i a_i a_i^T) - 1^T \lambda + n & \sum_{i=1}^m \lambda_i a_i a_i^T \succ 0 \\ -\infty & \text{otherwise} \end{cases}$$

- 对偶问题:

$$\begin{aligned} & \text{maximize} && \log \det(\sum_{i=1}^m \lambda_i a_i a_i^T) - 1^T \lambda + n \\ & \text{subject to} && \lambda \succeq 0 \end{aligned}$$



Minimum volume covering ellipsoid

- 弱化的Slater条件：存在 $X \in S_{++}^n$ ，满足

$$a_i^T X a_i \leq 1, i = 1, \dots, m$$

- 弱化的Slater条件总成立，因此该优化问题具有强对偶性。



对偶可行解的不等式

- 对于一优化问题，若 x 为一可行解， (λ, ν) 为对偶问题可行解，则有如下不等式：

$$f_0(x) - p^* \leq f_0(x) - g(\lambda, \nu)$$

x 为 ε -次优解，其中

$$\varepsilon = f_0(x) - g(\lambda, \nu)$$

- 不等式可以用于对次优解的精度估计

互补松弛条件

- 设 x^* 为原始优化问题的最优解, (λ^*, ν^*) 为对偶问题的最优解, 若两者具有强对偶性, 则

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, \nu^*) \\ &= \inf_x (f_0(x) + \sum_i \lambda_i^* f_i(x) + \sum_i \nu_i^* h_i(x)) \\ &\leq f_0(x^*) + \sum_i \lambda_i^* f_i(x^*) + \sum_i \nu_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

所以

$$\sum_i \lambda_i^* f_i(x^*) = 0$$

即

$$\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$$

KKT优化条件

- 设优化问题中，函数 $f_0(x), \dots, f_m(x), h_0(x), \dots, h_p(x)$ 可微。设 x^* 为原始优化问题的最优解， (λ^*, ν^*) 为对偶问题的最优解，且两者具有强对偶性，则 (x^*, λ^*, ν^*) 满足如下条件：

1. $f_i(x^*) \leq 0, i = 1, \dots, m$

2. $h_i(x^*) = 0, i = 1, \dots, p$

3. $\lambda_i^* \geq 0, i = 1, \dots, m$

4. $\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$

5. $\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p \nu_i^* \nabla h_i(x^*) = 0$

KKT条件为
必要条件！



凸优化问题的KKT条件

- 设原始问题为凸优化问题中，函数

$$f_0(x), \dots, f_m(x), h_0(x), \dots, h_p(x)$$

可微。设 $(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$ 满足KKT条件，则 \tilde{x} 为原始问题的最优解，而 $(\tilde{\lambda}, \tilde{\nu})$ 为对偶问题的最优解，且两者具有强对偶性。



例

■ 原始凸优化问题 minimize $-\sum_i \log(\alpha_i + x_i)$

subject to $x \succcurlyeq 0$

$$1^T x = 1$$

KKT条件 $x^* \succcurlyeq 0, 1^T x^* = 1, \lambda^* \succcurlyeq 0,$

$$\lambda_i^* x_i^* = 0, i = 1, \dots, n,$$

$$-1/(\alpha_i + x_i^*) - \lambda_i^* + \nu^* = 0, i = 1, \dots, n$$



例

解得

$$x_i^* = \begin{cases} 1/\nu^* - \alpha_i & \nu^* < 1/\alpha_i \\ 0 & \nu^* \geq 1/\alpha_i \end{cases}$$

其中

$$\sum_{i=1}^n \max\{0, 1/\nu^* - \alpha_i\} = 1$$



凸优化问题的对偶求解

- 设原始优化问题与对偶问题具有强对偶性，且 (λ^*, ν^*) 为对偶问题的最优解。 $L(x, \lambda^*, \nu^*)$ 存在唯一的最小解，即

$$\text{minimize } f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x)$$

存在唯一解 x^* 。若 x^* 为原始问题的可行解，则 x^* 即为原始问题的最优解；若 x^* 不是原始问题的可行解，则原始问题不存在最优解。



扰动问题

- 扰动问题:
$$\begin{aligned} &\text{minimize} && f_0(x) \\ &\text{subject to} && f_i(x) \leq u_i, \quad i = 1, \dots, m \\ &&& h_j(x) = v_j, \quad j = 1, \dots, p \end{aligned}$$
- 当 $u = 0, v = 0$ 时即为原始问题。
- 若 u_i 为正, 则第 i 个不等式约束被放宽; 若 u_i 为负, 则第 i 个不等式约束被收紧。
- 记 $p^*(u, v)$ 为扰动问题的最优解。若扰动问题无最优解, 则记

$$p^*(u, v) = \infty$$



灵敏度分析

- 设对偶问题存在最优解，且与原始问题具有强对偶性，若非干扰问题的最优对偶解为 (λ^*, ν^*) ，则有

$$p^*(u, \nu) \geq p^*(0, 0) - \lambda^{*T} u - \nu^{*T} \nu$$

- 若 $p^*(u, \nu)$ 在 $u = 0, \nu = 0$ 处可微，则

$$\lambda_i^* = -\frac{\partial p^*(0, 0)}{\partial u_i} \quad \nu_i^* = -\frac{\partial p^*(0, 0)}{\partial \nu_i}$$



选择定理

- 定义（弱选择性）：若两个不等式（等式）系统，至多有一个可解，则称这两个系统具有弱选择性。

- 设原始问题的约束条件：

$$f_i(x) \leq 0, i = 1, \dots, m, h_j(x) = 0, j = 1, \dots, p$$

- 对偶问题

$$g(\lambda, \nu) = \inf \left(\sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right)$$

- 对偶不等式组

$$\lambda \succeq 0, g(\lambda, \nu) > 0$$

- 原始问题的约束条件与对偶不等式组具有弱选择性。



选择定理

- 设原始问题的严格不等式约束条件:

$$f_i(x) < 0, i = 1, \dots, m, h_j(x) = 0, j = 1, \dots, p$$

- 对偶不等式组

$$\lambda \succeq 0, \lambda \neq 0, g(\lambda, \nu) \geq 0$$

- 原始问题的严格不等式约束条件与对偶不等式组具有弱选择性。



选择定理

- 定义（强选择性）：若两个不等式（等式）系统，恰有一个可解，则称这两个系统具有强选择性。

- 设原始问题为凸优化问题，其严格不等式约束条件为：

$$f_i(x) < 0, i = 1, \dots, m, Ax = b$$

- 对偶不等式组 $\lambda \succeq 0, \lambda \neq 0, g(\lambda, v) > 0$

- 若存在 $x \in \text{renlint} D$ ，满足 $Ax = b$ ，则上述两不等式约束系统具有强选择性。



选择定理

- 设原始问题为凸优化问题，其不等式约束条件为：

$$f_i(x) \leq 0, i = 1, \dots, m, Ax = b$$

- 对偶不等式组

$$\lambda \succeq 0, g(\lambda, \nu) > 0$$

- 若存在 $x \in \text{reint} D$ ，满足 $Ax = b$ ，且下述优化问题存在最优解

$$\text{minimize } s$$

$$\text{subject to } f_i(x) - s \leq 0, \quad i = 1, \dots, m$$

$$Ax = b$$

则原始问题的不等式约束条件与对偶不等式组具有强选择性。



凸优化理论与应用

第五章 逼近与拟合



范数逼近问题

- 问题描述:

$$\text{minimize} \quad \|Ax - b\|$$

$$A \in R^{m \times n}, m \geq n,$$

- 残差向量 $r = Ax - b$

- 范数逼近问题的原型

- 几何原型：在线性变换象集到某一点的最小距离。
- 优化设计原型：一个线性系统中与目标最接近的输入变量。



例

- 最小平方逼近：范数 $\|\cdot\|_2$
最优解满足：
$$A^T A x = A^T b$$
- 切比雪夫逼近：范数 $\|\cdot\|_\infty$ ，原问题转换为**LP**问题：

minimize t

subject to $-t \mathbf{1} \leq Ax - b \leq t \mathbf{1}$

- 残差绝对值和逼近：范数 $\|\cdot\|_1$ ，原问题转换为**LP**问题：

minimize $\mathbf{1}^T y$

subject to $-y \preceq Ax - b \preceq y$



罚函数逼近

- 问题描述：
$$\begin{aligned} &\text{minimize} && \sum_{i=1}^n \phi(r_i) \\ &\text{subject to} && r = Ax - b \end{aligned}$$
- 罚函数 $\phi(r)$ 表示逼近问题误差的代价，一般为对称、非负且 $\phi(0) = 0$
- 若罚函数为凸函数，则罚函数逼近问题为凸优化问题。



罚函数的例

- $l_p, p \geq 1$ 范数:

$$\phi(r) = |r|^p$$

- 死区线性罚函数:

$$\phi(r) = \begin{cases} 0 & |r| \leq a \\ |r| - a & |r| > a \end{cases}$$

- 对数门限罚函数

$$\phi(r) = \begin{cases} -a^2 \log(1 - (r/a)^2) & |r| < a \\ \infty & |r| \geq a \end{cases}$$



鲁棒的罚函数

- 若 $|r|$ 大到一定程度时，罚函数为 $|r|$ 的线性函数，则称该罚函数为鲁棒的罚函数。
- **Huber** 罚函数

$$\phi(r) = \begin{cases} r^2 & |r| \leq M \\ M(2|r| - M) & |r| > M \end{cases}$$



最小范数问题

- 问题描述: minimize $\|x\|$
subject to $Ax = b, A \in R^{m \times n}, m < n$
- 可以消去等式约束将其转换为范数逼近问题:

$$\text{minimize } \|x_0 + zu\|$$

其中 $x_0 + zu$ 为方程组 $Ax = b$ 的解。



最小范数问题

- 最小平方范数问题：范数 $\|\bullet\|_2$ ，最优解满足：

$$2x^* + A^T v^* = 0, Ax^* = b$$

- 最小罚问题： minimize $\sum_{i=1}^n \phi(x_i)$

$$\text{subject to } Ax = b$$

- 绝对值和最小问题：范数 $\|\bullet\|_1$ ，原问题可转换为LP问题：
minimize $1^T y$

$$\text{subject to } Ax = b, -y \preceq x \preceq y$$



正则逼近

- 二元矢量优化问题描述:

$$\text{minimize(w.r.t. } R_+^2) \quad (\|Ax - b\|, \|x\|)$$

- 正则化问题:

$$\text{minimize} \quad \|Ax - b\| + \gamma \|x\|, \gamma > 0$$

最优解描述了两分量的一条折中曲线。



正则逼近

- **Tikhonov**正则化问题:

$$\text{minimize} \quad \|Ax - b\|^2 + \delta \|x\|^2, \delta > 0$$

为二次优化问题:

$$\text{minimize} \quad x^T (A^T A + \delta I)x - 2b^T Ax + b^T b$$

最优解的形式:

$$x = (A^T A + \delta I)^{-1} A^T b$$



正则逼近

- Tikhonov光滑正则化问题:

$$\text{minimize } \|Ax - b\|^2 + \delta \|\Delta x\|^2, \delta > 0$$

Δx 为二阶差分算子:

$$\Delta x = n^2 \begin{bmatrix} 1 & -2 & 1 & 0 & \dots & 0 & 0 & 0 \\ 0 & 1 & -2 & 1 & \dots & 0 & 0 & 0 \\ 0 & 0 & 1 & -2 & \dots & 0 & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & 0 & \dots & -2 & 1 & 0 \\ 0 & 0 & 0 & 0 & \dots & 1 & -2 & 1 \end{bmatrix} x$$



信号复原

- 已知加噪信号:

$$x_{cor} = x + v$$

信号复原问题的描述:

$$\text{minimize(w.r.t. } R_+^2) \quad (\|\hat{x} - x_{cor}\|_2, \phi(\hat{x}))$$

函数 $\phi(\hat{x}): R^n \rightarrow R$ 为正则函数或光滑函数。

$$\phi_{quad}(\hat{x}) = \sum_{i=1}^{n-1} (\hat{x}_{i+1} - \hat{x}_i)^2 \quad \phi_{tv}(\hat{x}) = \sum_{i=1}^{n-1} |\hat{x}_{i+1} - \hat{x}_i|$$

信号复原




Figure 6.8 *Top: the original signal $x \in \mathbb{R}^{4000}$. Bottom: the corrupted signal x_{cor} .*

信号复原




Figure 6.9 Optimal trade-off curve between $\|D\hat{x}\|_2$ and $\|\hat{x} - x_{\text{cor}}\|_2$. The curve has a clear knee near $\|\hat{x} - x_{\text{cor}}\|_2 \approx 3$.

信号复原




Figure 6.10 Three smoothed or reconstructed signals \hat{x} . The top one corresponds to $\|\hat{x} - x_{\text{cor}}\|_2 = 8$, the middle one to $\|\hat{x} - x_{\text{cor}}\|_2 = 3$, and the bottom one to $\|\hat{x} - x_{\text{cor}}\|_2 = 1$.

鲁棒逼近

- 问题描述: minimize $\|Ax - b\|$, A 不确定
- 随机鲁棒逼近: A 为随机变量, 逼近问题转换为最小化期望
minimize $E(\|Ax - b\|)$

- 例: $P(A = A_i) = p_i$

随机鲁棒逼近为:

$$\text{minimize} \quad \sum_{i=1}^n p_i \|A_i x - b\|$$

转换为:

$$\begin{aligned} &\text{minimize} \quad p^T t \\ &\text{subject to} \quad \|A_i x - b\| \leq t_i, i = 1, \dots, n \end{aligned}$$



随机鲁棒逼近

- A 为随机变量: $A = \bar{A} + U$

最小平方随机鲁棒逼近为:

$$\text{minimize } E \|Ax - b\|_2^2$$

转换为:

$$\text{minimize } \|\bar{A}x - b\|_2^2 + \|P^{1/2}x\|_2^2$$

其中 $P = EU^T U$



最坏情况鲁棒逼近

- 考虑 $A \in I_A$ ，最坏情况鲁棒逼近为：

$$\text{minimize} \quad \sup_{A \in I_A} (\|Ax - b\|)$$

- 例：

随机鲁棒逼近为：

$$\text{minimize} \quad \sum_{i=1}^n p_i \|A_i x - b\|$$

转换为：

$$\begin{aligned} &\text{minimize} \quad p^T t \\ &\text{subject to} \quad \|A_i x - b\| \leq t_i, i = 1, \dots, n \end{aligned}$$



凸优化理论与应用

第6章 统计估计



概率分布的参数估计

- 随机变量的概率密度为 $p_x(\cdot)$ ，其中 x 为概率分布的参数，且参数未知。参数估计的目标就是通过一些已知样本估计获得参数的最优近似值。
- 问题描述
$$\text{maximize}(x \in C) \quad \log p_x(y)$$
- y 为样本观测值；
- $l(x) = \log p_x(y)$ 为对数似然函数；
- 若似然函数为凹函数，则优化问题为凸优化问题。



具有独立同分布噪声的线性测量

- 线性测量模型：
$$y_i = a_i^T x + v_i$$
- y_i 为观测值或测量值；
- $x \in R^n$ 为未知参数向量；
- v_i 独立同分布噪声，其概率密度为 p 。
- 似然函数为
$$p_x(y) = \prod_{i=1}^n p(y_i - a_i^T x)$$
- 最大似然估计问题为：
$$\text{maximize} \quad \sum_{i=1}^n \log p(y_i - a_i^T x)$$



例

- 高斯白噪声

$$p(r) = N(0, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{r^2}{2\sigma^2}}$$

对数似然函数:

$$l(x) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (a_i^T x - y_i)^2$$

- 区间 $[-a, a]$ 上均匀分布的噪声:

对数似然函数:

$$l(x) = \begin{cases} -n \log(2a) & |a_i^T x - y_i| \leq a, i = 1, \dots, n \\ -\infty & \text{otherwise} \end{cases}$$

逻辑回归

- 随机变量 $y \in \{0,1\}$ 的概率分布为:

$$p = \text{prob}(y = 1) = \frac{\exp(a^T u + b)}{1 + \exp(a^T u + b)}$$

- $a \in R^n, b \in R$ 为参数;
- $u \in R^n$ 为可观测的解释变量; (u_i, y_i) 为观察值。

对数似然函数: $(y_1 = \dots = y_k = 1, y_{k+1} = \dots = y_n = 0)$

$$\begin{aligned} l(a, b) &= \log\left(\prod_{i=1}^k \frac{\exp(a^T u_i + b)}{1 + \exp(a^T u_i + b)} \prod_{i=k+1}^n \frac{1}{1 + \exp(a^T u_i + b)}\right) \\ &= \sum_{i=1}^k (a^T u_i + b) - \sum_{i=1}^n (1 + \exp(a^T u_i + b)) \end{aligned}$$



假定测验

- 随机变量 $X \in \{1, 2, \dots, n\}$ ，有 m 种可能（假定）的分布；
- 假定 j ： X 的概率分布为 $p_j = \{p_{1j}, p_{2j}, \dots, p_{nj}\}$
- 假定测验的目标：由观察值猜测随机变量最有可能服从哪种假定的分布。
- 当 $m = 2$ 时，称为二元假定测验。
- 随机检测子：非负元素矩阵 $T \in R^{2 \times n}$

$$t_{ik} = \text{prob}(\hat{\theta} = i \mid x = k)$$

假定测验

- 检测概率矩阵

$$D = [T_1 \ T_2] = \begin{bmatrix} 1 - P_{fp} & P_{fn} \\ P_{fp} & 1 - P_{fn} \end{bmatrix}$$

- P_{fp} 为当 X 实际服从第**1**种假定分布而猜测为第**2**种假定分布的概率；
- P_{fn} 为当 X 实际服从第**2**种假定分布而猜测为第**1**种假定分布的概率；
- 多目标优化形式：

$$\text{minimize(w.r.t. } R_+^2) \quad (P_{fp}, P_{fn})$$

subject to

$$t_{1k} + t_{2k} = 1, k = 1, \dots, n$$

$$t_{1k} \geq 0, t_{2k} \geq 0, k = 1, \dots, n$$



假定测验

■ 尺度优化形式:

$$\text{minimize} \quad P_{fp} + \lambda P_{fn}$$

$$\text{subject to} \quad t_{1k} + t_{2k} = 1, k = 1, \dots, n$$

$$t_{1k} \geq 0, t_{2k} \geq 0, k = 1, \dots, n$$

■ 最小最大值形式

$$\text{minimize} \quad \max(P_{fp}, P_{fn})$$

$$\text{subject to} \quad t_{1k} + t_{2k} = 1, k = 1, \dots, n$$

$$t_{1k} \geq 0, t_{2k} \geq 0, k = 1, \dots, n$$




例

- X 在两种假设下的概率分布为:

$$P = \begin{bmatrix} 0.7 & 0.1 \\ 0.2 & 0.1 \\ 0.05 & 0.7 \\ 0.05 & 0.1 \end{bmatrix}$$

例



solutions 1, 2, 3 (and endpoints) are deterministic; 4 is minimax detector



实验设计

- 线性测量问题 $y_i = a_i^T x + w_i$
- w_i 独立同分布高斯白噪声，服从分布 $N(0,1)$ 。
- 最大似然估计值：

$$\hat{x} = \left(\sum_{i=1}^n a_i a_i^T \right)^{-1} \sum_{i=1}^n y_i a_i$$

- 估计误差 $e = \hat{x} - x$ 均值为**0**，方差为

$$E = E e e^T = \left(\sum_{i=1}^n a_i a_i^T \right)^{-1}$$

信赖椭圆为 $\{x \mid (x - \hat{x})^T E^{-1} (x - \hat{x}) \leq \beta\}$



实验设计

- 实验设计的目标：寻找 $a_i \in \{v_1, \dots, v_p\}$ ，使得误差的方差矩阵最小。

- 向量优化形式：

$$\begin{aligned} & \text{minimize (w.r.t. } S_+^n) & E &= \left(\sum_{k=1}^p m_k v_k v_k^T \right) \\ & \text{subject to} & m_k &\geq 0, m_1 + \dots + m_p = n \\ & & m_k &\in \mathbb{Z} \end{aligned}$$

- 为整数问题，求解较困难。



实验设计

- 当 $n \gg p$ 时，令 $\lambda_p = m_p / n$ 近似为一连续实数，原问题可松弛转换为连续实数优化：

$$\begin{aligned} & \text{minimize(w.r.t. } S_+^n) \quad E = \frac{1}{n} \left(\sum_{k=1}^p \lambda_k v_k v_k^T \right) \\ & \text{subject to} \quad \lambda \succeq 0, 1^T \lambda = 1 \end{aligned}$$



凸优化理论与应用

第7章 几何问题



体积问题

- 已知集合 C , E 为包含 C 的椭球, 满足:

$$E = \{v \mid \|Av + b\| \leq 1\}$$

- 求包含 C 的体积最小的椭球问题:

$$\begin{aligned} & \text{minimize} \quad \log \det A^{-1} \\ & \text{subject to} \quad \sup_{v \in C} \|Av + b\| \leq 1 \end{aligned}$$

- 若 C 为有限集, 则问题变为:

$$\begin{aligned} & \text{minimize} \quad \log \det A^{-1} \\ & \text{subject to} \quad \sup \|Av_i + b\| \leq 1, i = 1, \dots, m \end{aligned}$$



体积问题

- 已知凸集 C , E 为包含在 C 内的椭球, 满足:

$$E = \{Bu + b \mid \|u\|_2 \leq 1\}$$

- 求包含在 C 内的体积最大的椭球问题:

$$\begin{aligned} & \text{maximize} \quad \log \det B \\ & \text{subject to} \quad \sup_{\|u\|_2 \leq 1} I_C(Bu + d) \leq 0 \end{aligned}$$

- 若 C 为多面体, 则问题变为:

$$\begin{aligned} & \text{maximize} \quad \log \det B \\ & \text{subject to} \quad \|Ba_i\|_2 + a_i^T d \leq b_i, i = 1, \dots, m \end{aligned}$$



中心问题

- 已知凸集 C ，包含在 C 内的最大体积球的球心，称为 **Chebyshev** 中心。
- 已知凸集 C ，包含在 C 内的最大体积椭球的球心，称为 **MVE** 中心。



线性判别

- 两个可分离点集 $\{x_1, \dots, x_N\}$ 和 $\{y_1, \dots, y_M\}$

分割超平面满足:

$$a^T x_i + b > 0, i = 1, \dots, N, \text{ 且 } a^T y_i + b < 0, i = 1, \dots, M$$

可对其归一化:

$$a^T x_i + b \geq 1, i = 1, \dots, N, \text{ 且 } a^T y_i + b \leq -1, i = 1, \dots, M$$

线性判别

- 支撑超平面 $H1: a^T x_s + b = 1$

$$H2: a^T y_t + b = -1$$

两超平面之间的距离:


$$d(H1, H2) = 2 / \|a\|_2$$

最优线性分割问题:

$$\text{minimize } \|a\|_2 / 2$$

$$\text{subject to } a^T x_i + b \geq 1, i = 1, \dots, N$$

$$a^T y_i + b \leq -1, i = 1, \dots, M$$



线性判别


- 若两点集 $\{x_1, \dots, x_N\}$ 和 $\{y_1, \dots, y_M\}$ 不完全可分, 近似分割超平面问题:

$$\text{minimize} \quad 1^T u + 1^T v$$

$$\text{subject to} \quad a^T x_i + b \geq 1 - u_i, i = 1, \dots, N$$

$$a^T y_i + b \leq -1 + v_i, i = 1, \dots, M$$

$$u_i \geq 0, v_i \geq 0$$





线性判别

- 支持向量分类器问题:

$$\text{minimize} \quad \|a\|_2 + \lambda(1^T u + 1^T v)$$

$$\text{subject to} \quad a^T x_i + b \geq 1 - u_i, i = 1, \dots, N$$

$$a^T y_i + b \leq -1 + v_i, i = 1, \dots, M$$

$$u_i \geq 0, v_i \geq 0$$



凸优化理论与应用

第7章 无约束优化



无约束优化问题

- 问题描述: $\text{minimize } f(x)$

- $f(x)$ 为凸函数, 且二次可微。

- 无约束问题求解的两种方法:

- 求解梯度方程:

$$\nabla f(x^*) = 0$$

- 迭代逼近:

$$f(x^{(k)}) \rightarrow p^*$$



例

■ 二次优化:

$$\text{minimize} \quad \frac{1}{2} x^T P x + q^T x + r, P \in S_+^n$$

梯度方程

$$P x^* + q = 0$$



迭代起始点

- 起始点 $x^{(0)}$ 满足:
 1. $x^{(0)} \in \text{dom}f$;
 2. $S = \{x \in \text{dom}f \mid f(x) \leq f(x^{(0)})\}$ 为闭集。
- 满足条件2的几种函数:
 - 函数 $f(x)$ 任意下水平集都是闭集;
 - 函数的定义域为 R^n
 - 当 $x \rightarrow \text{bd dom}f$ 时, $f(x) \rightarrow \infty$



强凸性

- 定义：函数 $f(x)$ 在 S 上具有强凸性，若 $f(x)$ 满足

$$\nabla^2 f(x) \succcurlyeq mI, m > 0$$

- 若函数 $f(x)$ 具有强凸性，则有

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{m}{2} \|y - x\|_2^2$$

$$\geq f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2$$

- p^* 为最优值，则

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$



强凸性

- 若函数 $f(x)$ 在 S 上具有强凸性，则可以证明存在 $M > 0$ ，满足
$$\nabla^2 f(x) \preceq MI$$

则有

$$f(y) \leq f(x) + \nabla f(x)^T (y - x) + \frac{M}{2} \|y - x\|_2^2$$

- p^* 为最优值，则

$$p^* \leq f(x) - \frac{1}{2M} \|\nabla f(x)\|_2^2$$



强凸性

- 对于 $x \in S$, 矩阵 $\nabla^2 f(x) \in S_{++}^n$ 的特征值从大到小依次为 $\{\lambda_1, \dots, \lambda_n\}$ 。则有:

$$mI \prec \lambda_n I \prec \nabla^2 f(x) \prec \lambda_1 I \prec MI$$

- 定义: 矩阵 $\nabla^2 f(x) \in S_{++}^n$ 的条件数为最大特征值与最小特征值之比, 即 $r = \lambda_1 / \lambda_n$ 。
- 条件数的上界:

$$r \leq M / m$$



下降法

- 下降法的基本原理:

迭代 $x^{(k+1)} = x^{(k)} + t\Delta x$, 满足 $f(x^{(k+1)}) < f(x^{(k)})$

Δx 为下降方向, t 为步长因子。

- 对于凸函数 $f(x)$, 当 Δx 满足 $\nabla f(x)^T \Delta x < 0$ 时, 存在某个 t , 使得 $f(x^{(k+1)}) < f(x^{(k)})$ 。



下降法


- 下降法的一般步骤：
 - 给出初始点 $x \in \text{dom}f$ ；
 - 循环迭代
 - 计算下降方向 Δx ；
 - 搜索步长因子 t ；
 - 迭代: $x = x + t\Delta x$



步长因子搜索

- 精确一维搜索： $t = \arg \min_{t>0} f(x + t\Delta x)$
- 回溯一维搜索： 给定参数 $\alpha \in (0, 0.5), \beta \in (0, 1)$
 - 初始化： 令 $t = 1$ ；
 - 循环迭代
 - 若 $f(x + t\Delta x) < f(x) + \alpha t \nabla f(x)^T \Delta x$ ， 则终止退出；
 - 否则令 $t = \beta t$

步长因子搜索





梯度下降法

- 下降方向: $\Delta x = -\nabla f(x)$

- 终止条件: $\|\nabla f(x)\|_2 \leq \varepsilon$

- 收敛性:

$$f(x^{(k)}) - p^* \leq c^k (f(x^{(0)}) - p^*)$$

其中 $c \in (0,1)$ 。

- 算法简单，但收敛速度较慢。

收敛性分析

- 设函数 $f(x)$ 具有强凸性，则存在 $m > 0$ 和 $M > 0$ ，满足：

$$mI \preceq \nabla^2 f(x) \preceq MI$$

则有：

$$f(x - t\Delta x) \leq f(x) - t \|\nabla f(x)\|_2^2 + \frac{Mt^2}{2} \|\nabla f(x)\|_2^2$$

- 若 t 采用精确一维搜索，则 $t = 1/M$ ，收敛速度因子：

$$c = 1 - m/M$$

- 若 t 采用回溯一维搜索，收敛速度因子：

$$c = 1 - \min\{2m\alpha, 2\beta\alpha m/M\}$$

- 条件数越大，收敛速度越小。


例

$$\text{minimize} \quad \frac{1}{2}(x_1^2 + \gamma x_2^2), \gamma > 0$$

- 初始解为 $(\gamma, 1)$ ，采用精确一维搜索；

- 迭代：
$$x_1^{(k)} = \gamma \left(\frac{\gamma - 1}{\gamma + 1} \right)^k \quad x_2^{(k)} = \left(-\frac{\gamma - 1}{\gamma + 1} \right)^k$$

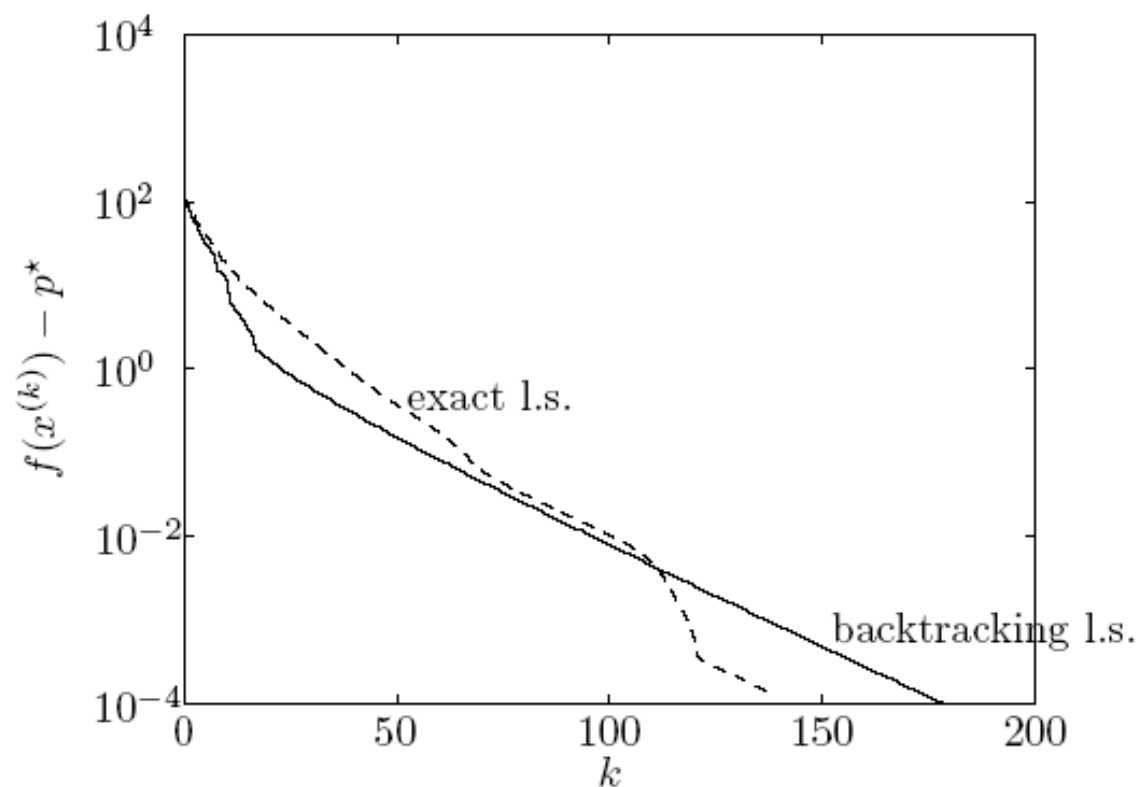
- 当 $\gamma \ll 1$ or $\gamma \gg 1$ 时，算法收敛速度很慢。



例

$$\text{minimize } c^T x - \sum_{i=1}^m \log(b_i - a_i^T x), m = 500, n = 100$$

- 步长因子采用回溯一维搜索。



最速下降法

- 归一化最速下降方向:

$$\Delta x_{nsd} = \arg \min_v \{ \nabla f(x)^T v \mid \|v\| = 1 \}$$

- 非归一化最速下降方向

$$\Delta x_{sd} = \|\nabla f(x)\|_* \Delta x_{nsd}$$

- 欧式范数: $\Delta x_{sd} = -\nabla f(x)$



- 二次范数 $\|x\|_P = (x^T P x)^{1/2}$:

$$\Delta x_{sd} = -P^{-1} \nabla f(x)$$

- l_1 -范数:

$$\Delta x_{sd} = -\frac{\partial f(x)}{\partial x_i} e_i$$

最速下降法





收敛性分析

- 范数界:

$$\|x\|_* \geq \gamma \|x\|_2, \gamma \in (0, 1]$$

- 收敛速度因子:

$$c = 1 - 2m\alpha\gamma^2 \min\{1, \beta\gamma^2 / M\}$$



牛顿法

- 设函数 $f(x)$ 二阶可微，则在 x 附近, $f(x)$ 的泰勒展式为：

$$\hat{f}(x + \Delta x) = f(x) + \nabla f(x)^T \Delta x + \frac{1}{2} \Delta x^T \nabla^2 f(x) \Delta x$$


- 泰勒展开可作为 $f(x)$ 在 x 附近的近似；

- 下降方向：

$$\Delta x_{nt} = -\nabla^2 f(x)^{-1} \nabla f(x)$$

- 为二次范数 $\|x\|_{\nabla^2 f(x)} = (x^T \nabla^2 f(x) x)^{1/2}$ 上的最速下降方向。

牛顿法





牛顿减量

- 令 $\lambda(x) = (\nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x))^{1/2}$

- $\lambda(x)$ 为 $f(x)$ 在 x 处的牛顿减量。

- 牛顿减量的性质1:

$$f(x) - \inf_y \hat{f}(y) = f(x) - \hat{f}(x + \Delta x_{nt}) = \frac{1}{2} \lambda(x)^2$$

牛顿减量可作为迭代求解的误差估计。

- 性质2: $\nabla f(x)^T \Delta x_{nt} = -\lambda(x)^2$

- 性质3: 牛顿减量具有仿射不变性。



牛顿方法

- 初始化：给定初始解 $x \in \text{dom}f$ 以及 $\varepsilon > 0$
- **LOOP:**
 - 计算：
$$\Delta x_{nt} = -\nabla^2 f(x)^{-1} \nabla f(x)$$
$$\lambda^2 = \nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x)$$
 - 若 $\lambda^2 / 2 < \varepsilon$ 则终止退出；
 - 一维线性搜索：计算步长因子 t ；
 - 迭代： $x = x + t \Delta x_{nt}$

收敛性分析

- 定理：假设 $f(x)$ 二阶连续可微，具有强凸性，即存在 $M > m > 0$ ，满足：

$$mI \preceq \nabla^2 f(x) \preceq MI$$

且海森矩阵满足**Lipschitz**条件，即存在 $L > 0$ ，满足：

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x - y\|_2$$

则存在 $0 < \eta < m^2 / L, \gamma > 0$ ，

若 $\|\nabla f(x^{(k)})\|_2 \geq \eta$ ，则 $f(x^{(k+1)}) - f(x^{(k)}) < -\gamma$ ；

若 $\|\nabla f(x^{(k)})\|_2 < \eta$ ，则 $t^{(k)} = 1$ ，且

$$\frac{L}{2m^2} \|\nabla f(x^{(k+1)})\|_2 \leq \left(\frac{L}{2m^2} \|\nabla f(x^{(k)})\|_2 \right)^2$$

收敛性分析

- 定理：假设 $f(x)$ 二阶连续可微，具有强凸性，即存在 $M > m > 0$ ，满足：

$$mI \preceq \nabla^2 f(x) \preceq MI$$

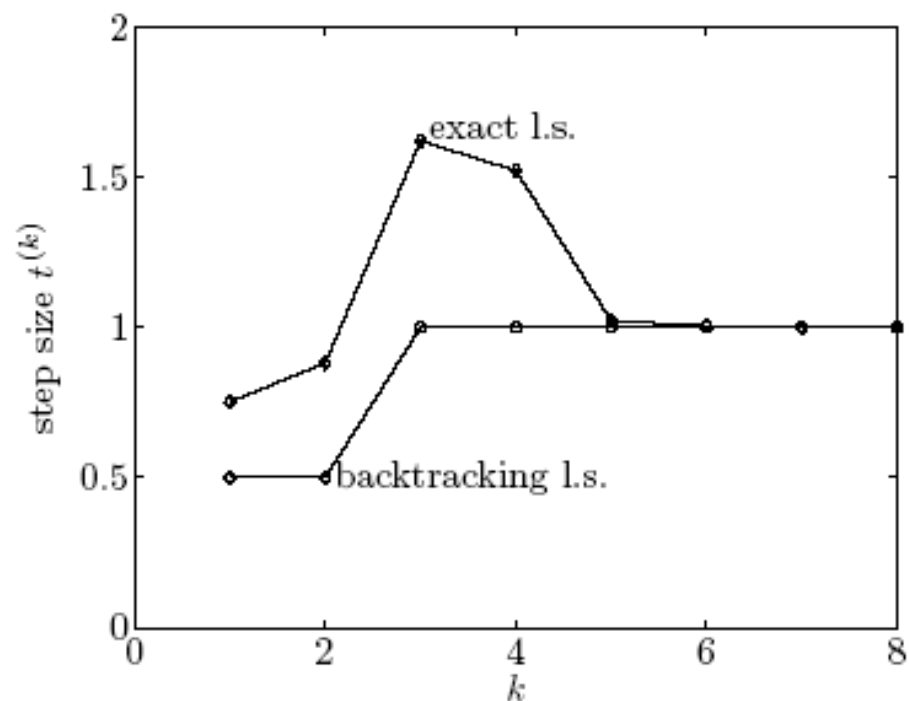

且海森矩阵满足**Lipschitz**条件，即存在 $L > 0$ ，满足：

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x - y\|_2$$

则存在 $k > 0$ ，对于 $l > k$ ，有

$$f(x^{(l)}) - p^* \leq \frac{1}{2m} \|\nabla f(x^{(l)})\|_2^2 \leq \frac{2m^3}{L^2} \left(\frac{1}{2}\right)^{2^{l-k+1}}$$

例





凸优化理论与应用

第8章 等式约束优化



等式约束优化问题

- 问题描述：
$$\begin{aligned} & \text{minimize} && f(x) \\ & \text{subject to} && Ax = b \end{aligned}$$
- $f(x)$ 为凸函数，且二次连续可微，且
$$A \in R^{p \times n}, p < n, \text{rank} A = p$$
- 假设最优值 p^* 存在，则 x^* 为最优解当且仅当存在 ν^* ，满足（KKT条件）：
$$\nabla f(x^*) + A^T \nu^* = 0, Ax^* = b$$



例

- 二次优化:
$$\begin{aligned} &\text{minimize} \quad \frac{1}{2} x^T P x + q^T x + r, P \in S_+^n \\ &\text{subject to} \quad A x = b \end{aligned}$$

KKT系统:

$$\begin{bmatrix} P & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ \nu^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}$$

- **KKT系统可解，则二次优化问题存在最优解。**
- **系数矩阵称为KKT矩阵。KKT矩阵非奇异当且仅当:**

$$A x = 0, x \neq 0 \Rightarrow x^T P x > 0$$



消去等式约束

- 方程组 $Ax = b$ 的解集:

$$\{x \mid Ax = b\} = \{Fz + \tilde{x} \mid z \in R^{n-p}\}$$

- \tilde{x} 为方程组的一个特解, F 为 A 的零空间范围。
- 无约束优化形式:

$$\text{minimize } f(Fz + \tilde{x}), z \in R^{n-p}$$

- 若 z^* 为最优解, 则有

$$x^* = Fz^* + \tilde{x} \quad v^* = -(A^T A)^{-1} A \nabla f(x^*)$$



对偶问题

- 对偶形式:

$$\text{maximize} \quad -b^T \nu - f^*(A^T \nu)$$

牛顿法

- x 为等式约束优化的可行解, 则在 x 附近原问题的二次近似为:

$$\text{minimize } \hat{f}(x+v) = f(x) + \nabla f(x)^T v + \frac{1}{2} v^T \nabla^2 f(x) v$$

$$\text{subject to } A(x+v) = b$$

- 设 Δx_{nt} 和 ω 分别为该问题和对偶问题的最优解, 则满足:

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{nt} \\ \omega \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

- 牛顿减量 $\lambda(x) = (\Delta x_{nt}^T \nabla^2 f(x) \Delta x_{nt})^{1/2}$



牛顿减量

- 牛顿减量 $\lambda(x) = (\Delta x_{nt}^T \nabla^2 f(x)^{-1} \Delta x_{nt})^{1/2}$

- 牛顿减量的性质：

$$f(x) - \inf\{\hat{f}(x+v) \mid A(x+v) = b\} = \frac{1}{2} \lambda(x)^2$$

- 性质2：牛顿减量具有仿射不变性。



可行下降方向

- 可行下降方向：设 x 满足方程组 $Ax = b$ 。若 v 满足方程组 $Av = 0$ ，则 $A(x + tv) = b$ 。 v 称为可行方向。若对于较小的 $t > 0$ ，有 $f(x + tv) < f(x)$ ，则 v 为可行下降方向。



等式约束的牛顿方法

- 初始化：给定初始解 $x \in \text{dom}f$ 满足 $Ax = b$ ，以及 $\varepsilon > 0$
- **LOOP:**
 - 计算 Δx_{nt} 及 λ^2 ；
 - 若 $\lambda^2 / 2 < \varepsilon$ 则终止退出；
 - 一维线性搜索：计算步长因子 t ；
 - 迭代： $x = x + t\Delta x_{nt}$



消去等式约束的牛顿方法

$$\text{minimize } \tilde{f}(z) = f(Fz + \tilde{x}), z \in R^{n-p}$$

- 初始值 $z^{(0)}$ ，第 k 次迭代值 $z^{(k)}$ ；
- 转换为等式约束下的牛顿方法：
 - 初始值： $x^{(0)} = Fz^{(0)} + \tilde{x}$
 - 迭代值： $x^{(k)} = Fz^{(k)} + \tilde{x}$

非可行解为初始点的牛顿法

- x 为等式约束优化的非可行解，则增量 Δx 应尽可能使 $x + \Delta x$ 满足KKT条件，即：

$$A(x + \Delta x) = b \quad \nabla f(x + \Delta x) + A^T \omega = 0$$

- 函数 $f(x)$ 二阶连续可微，因此有

$$\nabla f(x + \Delta x) \approx \nabla f(x) + \nabla^2 f(x) \Delta x$$

- 设 Δx_{nt} 和 ω 为KKT条件的解，即有：

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{nt} \\ \omega \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}$$



非可行解为初始点的牛顿法

- 令 $y = (x, v)$ $r(y) = (\nabla f(x) + A^T v, Ax - b)$

- 则KKT条件可表示为: $r(y) = 0$

- 设 y 为不满足KKT条件, 则其迭代量需满足:

$$r(y + \Delta y) \approx r(y) + Dr(y)\Delta y = 0$$

即

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{nt} \\ \Delta v_{nt} \end{bmatrix} = - \begin{bmatrix} \nabla f(x) + A^T v \\ Ax - b \end{bmatrix}$$



非可行解为初始点的牛顿法

- 初始化：给定初始解 $x \in \text{dom}f$ 及 v ，以及 $\varepsilon > 0$
- **LOOP:**
 - 计算 Δx_{nt} 和 Δv_{nt} ；
 - 回溯一维线性搜索：
 - 令 $t = 1$ ；
 - **While** $\|r(x + t\Delta x_{nt}, v + t\Delta v_{nt})\|_2 \geq (1 - \alpha t)\|r(x, v)\|_2$
 $t = \beta t$
 - 迭代： $x = x + t\Delta x_{nt}$ $v = v + t\Delta v_{nt}$
 - 当 $Ax = b$ 且 $\|r(y)\|_2 < \varepsilon$ 时，终止迭代。

KKT系统的求解

- KKT系统:
$$\begin{bmatrix} H & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} v \\ w \end{bmatrix} = - \begin{bmatrix} g \\ h \end{bmatrix}$$

- 1. LDL^T 分解;

- 2. 若 H 非奇异, 则可消元:

$$AH^{-1}A^T w = h - AH^{-1}g, Hv = -(g + A^T w)$$

- 3. 若 H 奇异, 则KKT系统可改写为:

$$\begin{bmatrix} H + A^T Q A & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} v \\ w \end{bmatrix} = - \begin{bmatrix} g + A^T Q h \\ h \end{bmatrix}$$

其中 $Q \succeq 0$, 且满足 $H + A^T Q A \succ 0$ 。



凸优化理论与应用

第9章 内点法



不等式约束优化问题

- 问题描述: minimize $f_0(x)$
subject to $f_i(x) \leq 0, i = 1, \dots, m$
 $Ax = b$
- $f_i(x)$ 为凸函数, 且二次连续可微, 且
$$A \in R^{p \times n}, p < n, \text{rank} A = p$$
- 假设最优值 p^* 存在;
- 假设存在 $\tilde{x} \in \text{dom} f$, 满足严格不等式条件 $f_i(x) < 0$
- 则优化问题具有强对偶性, 其对偶问题亦可解。



不等式约束的消去

- 示性函数消去不等式约束：

$$\text{minimize } f_0(x) + \sum_{i=1}^m I_-(f_i(x))$$

$$\text{subject to } Ax = b$$

$$I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u > 0 \end{cases}$$


- $I_-(u)$ 不具备良好的连续可微性，考虑用对数阀函数来近似替代。

对数熵函数

- 对于 $t > 0$, $-1/t \log(-u)$ 是 $I_-(u)$ 的光滑逼近。且当 $t \rightarrow \infty$ 时, 有

$$-1/t \log(-u) \rightarrow I_-(u)$$

- 令
$$\phi(x) = -\sum_{i=1}^m \log(-f_i(x))$$



- 带示性函数的优化问题可近似为:

$$\text{minimize} \quad f_0(x) + \frac{1}{t} \phi(x), t > 0$$

$$\text{subject to} \quad Ax = b$$



对数阀函数

- 对数阀函数 $\phi(x)$ 是凸函数
- 对数阀函数二阶连续可微，导数为：

$$\nabla \phi(x) = \sum_{i=1}^m \frac{1}{-f_i(x)} \nabla f_i(x)$$

$$\nabla^2 \phi(x) = \sum_{i=1}^m \frac{1}{f_i(x)^2} \nabla f_i(x) \nabla f_i(x)^T + \sum_{i=1}^m \frac{1}{-f_i(x)} \nabla^2 f_i(x)$$


中心线

- 对数阀近似问题的等价问题:

$$\text{minimize } tf_0(x) + \phi(x), t > 0$$

$$\text{subject to } Ax = b$$

- 最优解为 $x^*(t)$, 则最优解集 $\{x^*(t) | t > 0\}$ 称为优化问题的中心线。



中心线的对偶点

- 设 $x = x^*(t)$ ，则存在 w 满足KKT条件：

$$t \nabla f_0(x) + \sum_{i=1}^m \frac{1}{-f_i(x)} \nabla f_i(x) + A^T w = 0, Ax = b$$

- 令 $\lambda_i^*(t) = -\frac{1}{t f_i(x^*(t))}, v^*(t) = w / t$

则 $x = x^*(t)$ 是拉格朗日函数 $L(x, \lambda^*(t), v^*(t))$ 的最小值解。

$$L(x, \lambda^*(t), v^*(t)) = f_0(x) + \sum_{i=1}^m \lambda_i^*(t) f_i(x) + v^*(t)(Ax - b)$$

- $(\lambda^*(t), v^*(t))$ 为对偶问题的可行解。



中心线的对偶点

- 设 p^* 为原始问题的最优值，则有：

$$\begin{aligned} p^* &\geq g(\lambda^*(t), \nu^*(t)) \\ &= L(x^*(t), \lambda^*(t), \nu^*(t)) \\ &= f_0(x^*(t)) - m/t \end{aligned}$$

- 因此，当 $t \rightarrow \infty$ 时，有 $f_0(x^*(t)) \rightarrow p^*$ 。 $x^*(t)$ 为原始问题的 m/t -次优解。



阀方法

- 初始化：给定严格可行解 x , $t > 0$, $\mu > 1$, 及 $\varepsilon > 0$
- **LOOP:**
 - 中心步骤：以 x 为初始点求解优化问题 $x^*(t)$,

$$\begin{aligned} &\text{minimize} \quad tf_0(x) + \phi(x) \\ &\text{subject to} \quad Ax = b \end{aligned}$$
 - 迭代： $x = x^*(t)$
 - 终止条件：若 $m/t < \varepsilon$, 则终止退出。
 - 更新 t : $t = \mu t$



收敛性分析



- 外层循环迭代次数:

$$\left\lceil \frac{\log(m / (\varepsilon t^{(0)}))}{\log \mu} \right\rceil$$

- 中心步骤实质为一个无约束或等式约束优化问题，其收敛性分析与相应优化问题的收敛性分析结果一致。

例:

- LP问题: $m = 100, n = 50$
- 初始值: $t^{(0)} = 1, \varepsilon = 10^{-6}$



第一阶段方法

- 对于不等式约束的优化问题，如何寻找严格可行解或验证不可解？
- 求解优化问题： minimize s
subject to $f_i(x) \leq s, i = 1, \dots, m$
 $Ax = b$
- 该问题最优解存在，假设最优值为 \bar{p}^*
 - 当 $\bar{p}^* < 0$ 时，存在严格可行解；
 - 当 $\bar{p}^* > 0$ 时，原始问题不可解；
 - 当 $\bar{p}^* = 0$ 时，无法准确确定。



第一阶段方法

- 优化目标为逐项之和:

$$\text{minimize } 1^T s$$

$$\text{subject to } f_i(x) \leq s_i, i = 1, \dots, m$$

$$Ax = b$$

- 对于固定的 x , $s_i = \max\{f_i(x), 0\}$



寻找严格可行解的方法

- 牛顿法求解优化问题:

$$\text{minimize } s$$

$$\text{subject to } f_i(x) \leq s, i = 1, \dots, m$$

$$Ax = b$$

- 迭代终止条件: 当前解 $s^{(k)} < 0$, 即终止迭代, 严格可行解为 $x^{(k)}$ 。